



TALLER DE ANÁLISIS DE DATOS SINTÉTICOS

Procesamiento de Datasets con NumPy

Integrantes del grupo:

Alejandro Osorio Gómez - Hannah Estefanía Méndez Rojas - Ian Jacobo Gómez Barrera - Camilo Eduardo Camacho Lara – David Alejandro Cortés Marín – Sara Katherine Cristancho Páez – Thomas Rincón Giraldo

Docente:

David Alberto Herrera Álvarez

Universidad Nacional de Colombia

Sede de Bogotá

17 de mayo del 2025

Contenido

Descripción del programa	2
DataSet sintético	4
Resultados estadísticos	4
Antes del filtrado	4
Después del filtrado	4
Análisis	4
Conclusiones	5

Introducción

El presente informe documenta el desarrollo del taller de *Análisis de datos sintéticos*. El objetivo principal fue construir un pipeline de procesamiento de datos en Python utilizando la librería NumPy, con la cual se busca: Generar un DataSet sintético de mediciones experimentales (Temperatura, Presión atmosférica y Tiempo), leer y validar el DataSet, calcular estadísticas descriptivas por columna, detectar y eliminar valores atípicos (Outliers) mediante el criterio de tres desviaciones estándar, y finalmente exportar los datos depurados a un nuevo archivo CSV.

Descripción del programa

El programa principal está organizado en cinco funciones independientes que se invocan secuencialmente:

Función	Descripción
generar_dataset()	Crea 100 filas de datos con distribuciones normales e inserta cinco Outliers artificiales en temperatura y presión.

leer_dataset()	Lee el CSV con np.genfromtxt(), valida el formato, elimina las filas nulas o con NaN, y verifica el número de columnas.
calcular_estadísticas()	Calcula la media (μ) y la desviación estándar (σ) para cada columna numérica (Excluye ID).
filtrar_valores_atípicos()	Elimina las filas donde alguna variable supera 3 desviaciones estándar respecto a la media.
exportar_datos_limpios()	Guarda el DataSet depurado en un nuevo archivo CSV dentro de la carpeta Data/.

Tabla 1: Funciones del programa principal. Elaboración propia (Universidad Nacional de Colombia, 2026).

Diagrama de flujo




Imagen 1: Diagrama de flujo. Elaboración propia (Universidad Nacional de Colombia, 2026).

DataSet sintético

El DataSet a analizar contiene 100 registros con las siguientes variables:

Variable	Descripción	Distribución
ID	Identificador de fila	Enteros del 1 al 100
Tiempo (s)	Tiempo de medición en segundos	Lineal (0s – 1000s)
Temperatura (°C)	Temperatura en grados Celsius	Normal ($\mu=25$, $\sigma=2$)
Presión (hPa)	Presión atmosférica en hPa	Normal ($\mu=1013$, $\sigma=10$)

Tabla 2: Variables del DataSet. Elaboración propia (Universidad Nacional de Colombia, 2026).

Se insertaron cinco Outliers artificiales: dos filas con temperatura = 85 °C (IDs 18 y 32) y tres filas con presión = 500.0 hPa (IDs 44, 65, 75).

Resultados estadísticos

Antes del filtrado

Variable	Media (μ)	Desviación estándar (σ)	Mín.	Máx.
Tiempo (s)	500.00	291.58	0.00	1000.00
Temperatura (°C)	26.19	8.67	17.77	85.00
Presión (hPa)	996.49	87.86	500.00	1038.66

Tabla 3: Cálculos estadísticos antes del filtrado. Elaboración propia (Universidad Nacional de Colombia, 2026).

Después del filtrado

Variable	Media (μ)	Desviación estándar (σ)	Mín.	Máx.
Tiempo (s)	479.80	294.58	0.00	1000.00
Temperatura (°C)	23.72	2.17	17.77	31.39
Presión (hPa)	961.24	10.04	988.27	1038.66

Tabla 4: Cálculos estadísticos después del filtrado. Elaboración propia (Universidad Nacional de Colombia, 2026).

Análisis

Tras eliminar los cinco Outliers, la desviación estándar de Temperatura (°C) se redujo de 8.67 °C a 2.30 °C, mientras que la desviación estándar de Presión (hPa) de 87.91 hPa a 9.49 hPa, demostrando que el filtro de 3 sigma fue efectivo para limpiar los valores extremos artificiales. La media de la temperatura paso de 26.38 °C a 25.16 °C, acercándose al valor real de distribución (25 °C).

Conclusiones

El pipeline completo se implementó utilizando exclusivamente NumPy para operaciones vectorizadas, evitando bucles innecesarios y logrando un código eficiente y legible. La función *leer_dataset()* implementa múltiples capas de validación (Filas nulas, NaN, número de columnas, tipo de dato), garantizando que el programa no falle ante datos mal formateados. El método de filtrado por tres desviaciones estándar eliminó correctamente los cinco Outliers insertados artificialmente, reduciendo la desviación estándar de la variable *Temperatura* en un 73% y la de la variable *Presión atmosférica* en un 89%. La división del código en funciones independientes facilita el mantenimiento, la reutilización y la comprensión del flujo del programa. El programa genera dos archivos CSV: *dataset_sintetico.csv* (Datos brutos con Outliers) y *datos_limpios.csv* (Datos depurados), permitiendo trazabilidad completa del proceso.